

INDEPENDENT PAPER REVIEW PANEL

七篇 ICLR 2026 论文

独立三评详细报告

基于 autonomous-paper-agent 审稿协议的 21 份隔离评审与独立元评审

评审范围：C1 · C2 · C3 · P1 · P3 · P7 · S1

评分框架：ICLR 2026 · 总分 2 / 4 / 6 / 8 / 10

生成日期：2026-08-25

重要说明：本报告是内部投稿前质量控制，不是录用概率预测。三位评审彼此隔离，元评审仅在三份评分全部提交后介入。

目录

- 1. 执行摘要与全局评分矩阵
- 2. 评审方法、独立性与评分尺度
- 3. C1 详细评审
- 4. C2 详细评审
- 5. C3 详细评审
- 6. P1 详细评审
- 7. P3 详细评审
- 8. P7 详细评审
- 9. S1 详细评审
- 10. 独立元评审与跨论文共同问题
- 11. 附录：评审标识、rubric 与文件哈希

执行摘要与全局评分矩阵

结论摘要 C1 与 C2 的三评中位数为 6；P3、P7、S1 为 4；C3 与 P1 为 2。P1 是唯一三位评审一致给 2 的论文，P7 是唯一三位一致给 4 的论文；没有论文获得 8 或 10。

表中三位评审依次为技术可靠性（R1）、实验严谨性（R2）和新颖性定位（R3）。维度中位数顺序为 Soundness / Presentation / Contribution；总分是整体 ICLR 判断，不由三个维度求平均。

论文	R1 技术	R2 实验	R3 新颖性	中位数	元评审	S / P / C 中位数	Critical
C1	4	6	6	6	6	3 / 3 / 3	无
C2	4	6	6	6	4	2 / 3 / 3	R1 1 项
C3	2	4	2	2	2	2 / 3 / 1	R1、R3 各 1 项
P1	2	2	2	2	2	2 / 2 / 1	三评均有
P3	2	4	4	4	4	2 / 3 / 2	三评均有
P7	4	4	4	4	4	2 / 3 / 2	无
S1	2	4	4	4	4	2 / 3 / 2	三评均有

总体判读

- C1 的主要分歧是：校准协议的系统化实证是否已经构成边缘接收，还是仍停留在描述性报告规则；三位都要求 selection-aware 重采样并修正 15/17 计数问题。
- C2 的主要分歧是：同检索下 24–27 pp 的窄负面结果能否抵消 A/E 深度归因的上下文集合混杂和评分器敏感性。
- C3 与 P1 的共同上限是方法学/治理资产缺少独立真值、外部校准及相对成熟工具的增量证据。
- P3 的冻结控制触发后被事后重新解释；P7 的候选信号主要是深度代理；S1 的 0.118 pp 范围无法用单检查点 0.52 pp 边际 SE 支持统计负面结论。
- 是否使用 dLLM 从未作为评分条件；评审只根据每篇自己的主张、方法、证据、贡献与可复现性判断。

评审方法、独立性与评分尺度

独立性设计 三位评审均使用全新的一次性子代理，并各自完整评审同一批七份冻结 PDF。评分提交前不得访问另外两人的输出、旧稿、旧评分、作者计划或仓库历史。元评审只在 21 份评分全部提交后启动。

- 论文及其中任何指令均被视为不可信评审对象；嵌入式指令不得改变评审角色或 rubric。
- 三个主专长分别为 novelty_positioning、technical_soundness、experimental_rigor；每位仍需评价整篇论文。
- 用户要求每篇三次独立评分，因此本轮使用三位而非技能默认的五位；这是明确的任务范围调整。
- 评审未做外部联网文献审计，故新颖性判断主要依据 PDF 自身引用、指定 KV-cache 定性锚点与领域知识。
- 主代理没有追加第四次独立评分；元评审分是面积主席式综合，不计入三次独立评分。
- 每份评审均绑定原始 PDF 的 SHA-256；七份 PDF 在评审前冻结。
- 一位评审的 AI 评审披露字段最初误写为论文作者披露状态，已做纯格式修正；评分与判断未改变。

ICLR 2026 评分语义

总分	含义
2	Reject : 当前版本不足以达到 ICLR 要求
4	Marginally below : 拒绝理由略强, 但可接受也并非不可理解
6	Marginally above : 接收理由略强, 但拒绝也并非不可理解
8	Accept : 适合作为 poster 的好论文
10	Strong accept : 应被会议重点展示

三个官方维度 Soundness、Presentation、Contribution 各使用 1-4 ; Confidence 使用 1-5。

冻结文件清单

编号	SHA-256	源文件
C1	ad12a865f6aa40b345319158357dcd696564c0825ac320ab9b07b9a75a1b8a57	/Users/liuhanzuo/Downloads/C1-paper (1).pdf
C2	7c8a617ddf4364056b71e15e97d7ee03421aba18edca01d94c53756a498fd6ef	/Users/liuhanzuo/Downloads/C2-paper.pdf
C3	6e4109840e80f6ee0e92142b717cee0ccf08393b13cd75d090a0684665f9ec01	/Users/liuhanzuo/Downloads/C3-paper.pdf
P1	bad75b40153309d97837b9a34bca37db62959570369c191e6f973ac5258fb303	/Users/liuhanzuo/Downloads/P1-paper (1).pdf
P3	06510f2d83e09a7647f7efcd1abfadc4350da3438b5d7a23452297ccf9d84c5b	/Users/liuhanzuo/Downloads/P3-paper (1).pdf
P7	a6e9c44d17e1e89d1a2987c83883f59c8e2ce524762476f77624b791f11fe859	/Users/liuhanzuo/Downloads/P7-paper.pdf
S1	80a3b9dd0c1e49b863330f9f71cce333321d0b8bfe78d3375cc3c1ca81070a64	/Users/liuhanzuo/Downloads/S1-paper (1).pdf

C1 — Null Calibration for Multiple-Choice Evaluation: When “Above Chance” Fails the Input-Blind Floor

一句话定位。 论文主张在解释多项选择评测的模型臂差异前，先用构造相适配的输入盲最佳常数预测器进行校准，并另以臂条件置换零假设判断单臂是否携带项目级信息；其当前证据覆盖 MMLU-Pro 与五个较小基准上的完整配对分析。

1. 三评评分

评审	评审侧重	Overall	Soundness	Presentation	Contribution	Confidence	当前证据上限 (ceiling)
R1	technical soundness	4	2	3	2	4	6
R2	experimental rigor	6	3	3	3	4	6
R3	novelty / positioning	6	3	3	3	4	6

2. 共识优点

- 三位评审认可论文明确区分 v1 与 v2：v1 服务于构造级输入盲 floor 的报告，v2 服务于臂条件、项目级信息判断，避免把两个问题混成一个统计结论。
- 完整表格、成对样本分析和逐单元报告使主要数字具有较高可审计性。
- 论文没有隐藏实现缺陷、事后修改或多重校正边界；这些限制被显式写入正文和附录。

3. 共识主要问题

下列问题是三份评审中反复出现或相互指向的风险簇；“来源”保留各评审原本的关注点，不把不同意见平均成单一意见。

3.1 输入盲零假设族与“gate”解释仍未闭合

- **定位**：p.1、p.3–4、p.6、p.8，以及 p.15–17。
- **来源**：R1 指出，同一数据集的各模型臂减去共同 floor 并不会改变臂间差值，因此 p.1/3/8 的 gate 有效性措辞仍偏强；R1 还指出当前 null family 主要是常数/最长选项，不能覆盖全部 input-blind 预测器。R2 指出“最强 construct-appropriate null”的候选族没有封闭。R3 指出用同一测试标签选出最佳常数预测器更接近预言机选择。
- **为何影响决策**：这是论文核心构念的定义边界。若“最强”只是在未封闭候选族中的最强，或 floor 并不改变臂间差异，则证据最多支持一项受限报告惯例，不能自动支持更强的有效性 gate。R1 因此把 Soundness 评为 2、Overall 评为 4；R2/R3 在较窄边界下仍给 Overall 6。
- **最小修复与验证**：明确封闭可选择的 input-blind 候选族；把“报告惯例”与“逻辑有效性 gate”在所有载荷句中保持一致；对使用同一测试标签选择最佳常数的步骤给出独立选择或选择校正。验证标准是：候选族、选择数据和最终检验数据的关系可逐项审计，且删去或收窄所有超出该族的“最强”表述。

3.2 胜出标签选择未进入 bootstrap，且依赖单元缺少总体检验

- **定位**：p.5、p.7、p.9、p.13、p.18–19，以及 p.23–25。
- **来源**：R1 指出胜出标签被固定，缺少 selection-aware bootstrap；并指出未校正计数与“模型族 × 损伤”单元不平衡。R2 同样指出 p.5/7/23 的 bootstrap 没有重做选择，并指出 p.6–7、p.18–19、p.23–25 的依赖单元没有全局层级检验。R3 也把 selection-aware 推断和总体依赖列为主要问题。
- **为何影响决策**：论文的主要计数由许多相关单元组成；若标签选择固定在重采样之外，区间可能忽略选择不确定性，而逐单元显著性不能替代模型族与损伤结构上的总体推断。这直接限制跨单元、跨族结论的强度。
- **最小修复与验证**：在每次 bootstrap 重采样中重新执行胜出标签选择，并对依赖单元给出全局层级检验或等价的依赖感知校正；同时分层报告模型族 × 损伤的不平衡。验证标准是：selection-aware 结果、校正前结果和总体检验并列，且载荷计数在预先声明的校正规则下仍成立。

3.3 关键计数存在 15/17 与实际交集 13 的不一致，v2 又带有后验性

- **定位**：p.5、p.9 §6、Table 15，以及 p.23–25。
- **来源**：R2 指出 §6 写的是“15/17 同时未过 floor 且高于 chance”，但与 Table 15 不符；按表中两个条件的实际交集应为 13。R2 还指出 v2 是后验加入。R1/R3 的 selection-aware 质疑与此相邻，但二者没有另报“13”这一具体核算。
- **为何影响决策**：15/17 是讨论段的载荷数字；集合交集错误会直接改变论文用来概括现象普遍性的比例。v2 的后验性质又意味着其验证强度不能与预注册分析等量齐观。
- **最小修复与验证**：将 §6 的 15/17 改为与 Table 15 一致的实际交集 13，或明确给出另一可复算的集合定义；把 v2 标为后验分析，并在新的冻结数据或预先声明的分析上验证。验证标准是：正文数字能从 Table 15 逐行复算，且 v2 的先验/后验状态在摘要、正文和附录一致。

3.4 证据主要来自人工损伤臂，常规模型与自然分布上的泛化仍未建立

- **定位**：p.6–9、p.13–14，以及 p.23。
- **来源**：R3 指出主要证据来自人工损伤臂，常规模型上的泛化未证。R1 指出模型族 × 损伤的不平衡；R2 指出依赖单元和后验 v2 使总体外推受限。
- **为何影响决策**：当前结果能说明这些受控损伤条件下，chance 与 input-blind floor 会给出不同读法；它尚不足以证明该现象在常规模型、自然退化或更均衡的模型族上具有同样频率和决策价值。
- **最小修复与验证**：在常规模型或自然退化条件上加入同一套冻结分析，并使模型族 × 损伤设计更均衡；继续按相同 floor、选择校正和总体检验报告。验证标准是：结论无需依赖人工损伤臂占主导仍能复现，或把正文范围严格收窄到当前损伤设定。

4. 各评审独有重点

- **R1**：特别强调“减去共同 floor 不改变臂差值”这一概念点，并把 null family 过窄与 gate 措辞过强联系起来；同时点出模型族 × 损伤不平衡。
- **R2**：独自核出 p.9 §6 的 15/17 与 Table 15 实际交集 13 不一致，并明确把 v2 的后验性列为问题。

- **R3**：特别强调核心统计思想已有先例，要求核验 p.2–5 的原创性边界；同时把“同一测试标签选最佳常数”描述为接近预言机的选择，并强调人工损伤臂之外的泛化缺口。

5. 分数分歧说明

R1 给 4，而 R2/R3 给 6；三者 Confidence 均为 4，ceiling 均为 6。伴随这一分歧的重点是：R1 把共同 floor 与 gate 构念、未封闭 null family 视为会压低当前技术可靠性的核心问题；R2/R3 虽报告选择校正、依赖、计数一致性与新颖性边界问题，但其提交分仍把这项工作放在可接收边缘的 6。这里不把两种判断合并成平均分。

6. 当前证据上限与可提分证据

- **当前上限**：三评一致为 6。
- **达到该上限所需的最小证据组合**：selection-aware bootstrap；依赖单元的总层检验或等价校正；封闭且可审计的 input-blind 候选族；修正 15/17 与实际交集 13 的矛盾；将后验 v2 与预先声明验证分开；在常规模型或自然退化条件上验证，或严格收窄泛化措辞。
- **新颖性核验**：对 p.2–5 所依赖的已有统计先例做逐项定位，明确真正新增的是报告规范、构造适配 null、实验发现，还是其组合。

7. 作者问题

12. 你们定义的“最强 construct-appropriate input-blind predictor”究竟对应哪个封闭候选族，为什么当前常数/最长选项候选足以支持“最强”的措辞？
13. 若同一数据集上所有臂都减去共同 floor 而臂间差值不变，哪些具体结论依赖 floor，哪些只应被表述为报告标签？
14. 能否在每次 bootstrap 内重新选择胜出标签，并给出对依赖单元的总层检验？
15. p.9 §6 的“15/17 同时未过 floor 且高于 chance”如何由 Table 15 复算？若是集合交集，为何不是 13？
16. v2 的后验性质如何在载荷结论中体现，能否在新的冻结分析上预先声明后复验？
17. 人工损伤臂上的结果能否在常规模型或自然退化条件下复现？若不能，正文将如何收窄范围？

8. 伦理与评审局限

- 提供的三评摘要没有记录针对 C1 的独立伦理异议；本整理不补写未提交的伦理判断。
- 三位评审的 Confidence 均为 4/5，不是最高置信度。R3 明确要求外部核验核心统计先例与原创性边界，因此本章不能把“新颖性已证”视为已完成事项。
- 本章只忠实整理评审摘要；未提供的原始 ethics 字段、逐字措辞或未列出的次要问题不在此复原。

C2 — *The Measured Cost of Cached-Depth Read-Out: a Matched, Pre-registered Negative Result for Hidden-State Cache in Long-Context Inference*

一句话定位。 论文用冻结 Qwen3-8B、同题同检索的匹配协议研究长上下文隐藏状态缓存：固定 top-k 检索维持短读工作点，但 j=12 相比 j=0 的读出准确率低约 24–27 个百分点，而局部读入显存只节省约 0.3 GB，因此把深度缓存界定为一个测得的质量与成本负结果，而非系统胜利。

1. 三评评分

评审	评审侧重	Overall	Soundness	Presentation	Contribution	Confidence	当前证据上限 (ceiling)
R1	technical soundness	4	2	3	2	4	4
R2	experimental rigor	6	3	3	3	4	6
R3	novelty / positioning	6	2	3	3	4	6

2. 共识优点

- 同一检索结果下设置 j=0 对照，使 j=12 与 j=0 的 24–27 pp 差异比“完整上下文 vs. 检索”比较更接近论文要问的深度读出问题。
- 内容哈希配对、深度扫描和五臂分解提高了样本对应关系与机制拆解的可审计性。
- 论文诚实限定系统边界：0.3 GB 是固定 6.7k-token 读入长度下的局部显存差，不是端到端、常数内存或“缓存免费”结论。

3. 共识主要问题

3.1 核心读出对 first-task-label / strip 规则敏感

- **定位**：p.6，以及 p.21、p.23。
- **来源**：R1、R2、R3 均指出 first-task-label 读出脆弱；更换 strip 规则可以改变甚至反转符号，answer-anchored、cap=512 的敏感性检验约为 $p \approx 0.0649$ ，跨过零。
- **为何影响决策**：24–27 pp 是在指定 reader 下的方向性结果，但幅度与显著性并非跨读出约定稳健。若载荷句越过 pinned reader 的范围，就会把约定依赖的负结果误写成一般性读出退化。
- **最小修复与验证**：预先固定读出规则，并同时报告原 reader、替代 strip 与 answer-anchored 结果；要么在独立冻结样本上证明方向对合理读出约定稳健，要么把所有载荷句严格限定为 pinned first-task-label reader。验证标准是：替代规则不再改变载荷结论，或正文明确不声称约定无关的方向和幅度。

3.2 Table 3 的 A/E “depth-only”对比仍改变下层上下文集合

- **定位**：p.7–8，Table 3。
- **来源**：R1、R2、R3 均指出 A 与 E 不只改变缓存深度：A 的下层看到选中 pack，E 的存储状态则来自连续文档区域，因此下层上下文集合同时变化。这是中心因果归因混杂。
- **为何影响决策**：五臂分解可以说明部署图中两个具体臂不同，但不能仅凭 A/E 就把全部差异因果归于 cache depth。R1 将这一中心归因缺口视为把当前 ceiling 压到 4 的原因之一；R2/R3 只在较窄的方向性负结果下给 6。
- **最小修复与验证**：运行一个使 A 的下层也在与 E 相同连续区域上计算、只改变 read-out depth 的无混杂臂。验证标准是：在下层上下文集合一致后， $j=12$ 相对 $j=0$ 的差异仍存在；否则将“depth-only”改为仅描述计算图而非去混杂因果对比。

3.3 4k 决策点从 1k 移动，且是 2k/4k/8k 中幅度最大者，未做选择校正

- **定位**：p.6，以及 p.27。
- **来源**：三评共同指出，预注册 anchor 从 1k 移到 4k，且 4k 是有效展示的 2k/4k/8k 单元中显著差距最大的一个；当前没有对这一选择做校正。

- **为何影响决策**：+27 pp 可以是选中单元的描述值，但不能在没有选择校正时充当预先固定的效应大小。它影响的不是问题同检索方向本身，而是载荷幅度与其确认性地位。
- **最小修复与验证**：把 4k 明确标为选择后的描述性幅度，并对 2k/4k/8k 的选择做校正；或在新冻结样本中预先固定 4k 后复验。验证标准是：校正或独立复验后，方向和声明的幅度区间仍成立。

3.4 系统与泛化证据过窄，26 次 break-even 依赖粗粒度中位数

- **定位**：p.2–9、p.18。
- **来源**：三评共同指出当前只测 Qwen3-8B、qa1、oracle BM25，且不是完整逐 token 生命周期；decode、索引、并发等系统面没有完整测量。所谓约 26 次查询的 break-even 来自粗粒度中位数。R3 另外指出 p.2–3、p.12–13 的最近系统没有同床实现或逐项核验。
- **为何影响决策**：当前结果支持一个窄配置下的匹配负结果，不能据此推出一隐藏状态缓存、端到端 serving 或跨系统结论；break-even 也不能被当成精确部署阈值。
- **最小修复与验证**：在同一端到端协议中加入 decode、索引和并发，并在更多模型、任务与非 oracle 检索上复验；对 break-even 保存并报告足够精度的原始时间而非仅依赖粗中位数；对最近系统做同床实现或逐项可核验比较。验证标准是：端到端结论在完整生命周期和至少一个额外模型/任务上成立，或所有结论继续限定在当前 Qwen3-8B/qa1/oracle-BM25 工作点。

3.5 部分输入不可恢复，限制独立复算

- **定位**：p.26–29。
- **来源**：R1 单独指出部分输入不可恢复；该问题与三评共同认可的内容哈希配对优点并存。
- **为何影响决策**：已冻结输出可以检查配对与现有表值，但缺失输入会阻止第三方从原始输入重新执行对应部分，因此不能把“可审计结果”扩写成完整端到端可复现。
- **最小修复与验证**：补齐可合法发布的缺失输入及其哈希，或逐项标明哪些单元只能复算、不能重跑。验证标准是：独立读者能够按清单区分 fully rerunnable 与 output-verifiable 的部分，且载荷句不越过该边界。

4. 各评审独有重点

- **R1**：特别强调 p.26–29 的输入不可恢复，并认为中心归因混杂与读出敏感性使当前证据上限只能为 4。
- **R2**：没有在提供的摘要中增加独有问题；其重点集中在与其他评审共同报告的读出敏感性、A/E 混杂、4k 选择及窄系统范围。
- **R3**：另外要求对 p.2–3、p.12–13 的最近系统做同床实现或逐项核验；在 Soundness 给 2 的同时，仍把窄配置方向性贡献评为 Contribution 3、Overall 6。

5. 分数分歧说明

R1 给 Overall 4、ceiling 4；R2/R3 给 Overall 6、ceiling 6。原评审摘要明确记录的分歧是：R1 认为 A/E 中心归因缺口与读出规则敏感性阻止论文越过 4；R2/R3 认为，在明确限定为单一 Qwen3-8B/qa1/oracle-BM25 配置的前提下，“同题同检索的方向性负结果”本身足以达到 6，但不支持广泛的深度因果或系统结论。三位评审的 Confidence 均为 4。

6. 当前证据上限与可提分证据

- **当前上限存在真实分歧**：R1 为 4；R2/R3 为 6，不能平均成一个上限。
- **支撑窄范围 6 所需证据**：将读出敏感性、4k 选择和 A/E 未去混杂边界完整写入载荷句；保证 24–27 pp 只对应 pinned reader 和指定工作点；把 0.3 GB 只写成局部读入差。
- **解除 R1 ceiling=4 所需的最小证据**：无混杂 A/E 对照；预先固定或选择校正后的读出与 4k 决策；可恢复输入或严格的可复现分级。
- **更强系统结论所需证据**：完整逐 token 生命周期中的 decode、索引和并发测量，更多模型/任务/检索器，以及用原始时间数据验证约 26 次 break-even。

7. 作者问题

18. 在替代 strip 规则可反转符号、answer-anchored cap=512 的 $p \approx 0.0649$ 跨零时，哪些结论仍被视为 reader-independent？
19. 能否加入一个使下层上下文集合完全一致、只改变 $j=0$ 与 $j=12$ read-out depth 的对照臂？
20. 4k 从 1k 移动且是 2k/4k/8k 中幅度最大者后，如何进行选择校正，或能否在新冻结样本上预先固定 4k 复验？

21. 约 26 次查询的 break-even 在只保留粗粒度中位数时有多大可复算精度？
22. 哪些 p.26–29 所需输入仍不可恢复，哪些结果只能核验输出而不能端到端重跑？
23. 最近相关系统能否在同床实现中逐项比较；若不能，论文如何限制 positioning？

8. 伦理与评审局限

- 提供的三评摘要没有记录针对 C2 的独立伦理异议；本整理不补写未提交的伦理判断。
- 三位评审 Confidence 均为 4/5。评审结论受限于单模型、单 qa1 任务、oracle BM25 和非完整逐 token 生命周期；R3 另指出最近系统尚未同床或逐项核验。
- “约 26 次 break-even”来自粗中位数，不能在本章中被转写成精确部署阈值。

C3 — *An Honest-Methodology Note: A NOT_MEASURED Register for a Withdrawn KV-Selective Serving Study*

一句话定位。 这是一篇撤回研究的方法学说明：它用 MEASURED / DERIVED / NOT_MEASURED 等作用域标签和 NOT_MEASURED register 保存证据边界，并报告一次 32k 修复后测量——加入约两行 inference-mode guard 后，Qwen3-8B 在单 H20-3e 上以 G=1 达到 29.31 GB 峰值且有限解码、不再 OOM；KV-selector、adapter-matched 与 16k 并发复测仍未完成。

1. 三评评分

评审	评审侧重	Overall	Soundness	Presentation	Contribution	Confidence	当前证据上限 (ceiling)
R1	technical soundness	2	2	2	1	4	4
R2	experimental rigor	4	2	3	1	4	4
R3	novelty / positioning	2	2	3	1	4	4

2. 共识优点

- 三评共同认可论文诚实撤回此前“环境不可行”的解释，没有用新的措辞掩盖缺失测量。
- MEASURED、DERIVED、NOT_MEASURED 的区分清楚，按行绑定作用域有助于防止把串行、并发、质量和推导量混写。
- D1 的局部 32k 修复记录可信：它表明缺失 inference-mode guard 是应用级测量缺陷，并确认修复后该单点可运行；论文没有把这一点冒充完整 KV-selective serving 结论。

3. 共识主要问题

3.1 Ledger 完整性只相对作者自报全集，生成器与检查器同源

- **定位：** p.3–4、p.6，以及 p.10–12。
- **来源：** R1、R2、R3 均指出 register 的“完整”只相对于作者自己枚举的 claim ledger，而不是独立 ground truth；生成器与检查器同源，不能独立证明没有漏项。
- **为何影响决策：** 该工具能检查“已登记 claim 是否被正确标记”，但不能据此证明“所有应登记 claim 都已登记”。这限制了完整性与可迁移性主张，也是三评 Contribution 均为 1、ceiling 均为 4 的核心边界。
- **最小修复与验证：** 用独立于生成器的人工或工具建立 claim ground truth，并盲测 ledger 的漏报与误报；把“complete”严格限定为 author-declared universe，直到独立全集验证完成。验证标准是：独立 gold ledger、匹配规则和错误清单可复查，且工具不再用自身输出证明自身完整。

3.2 Regex/局部窗口不能保证语义覆盖；27 个结构中有 9 个不覆盖

- **定位：** p.3–4、p.9，以及 p.12。
- **来源：** 三评共同指出，regex 和局部上下文窗口只能命中表面模式，不能保证语义；27 个检查结构中有 9 个不覆盖，且同义改写可绕过。
- **为何影响决策：** 若 gate 容易被措辞变化绕开，它只能是必要的 hygiene filter，不能承担完整 honesty certificate。其结果也不能被解释为语义层面的无遗漏审计。
- **最小修复与验证：** 对 27 个结构逐项报告覆盖状态，并用同义改写/改序等已指出的绕过方式做盲测；对 9 个未覆盖结构补规则或明确保留 NOT_COVERED。验证标准是：已知同义改写不再无声绕过，或输出显式标记无法做语义判断的单元。

3.3 跨项目验证只有命中计数，没有独立 ground truth 或效用指标

- **定位：** p.8–10，以及 p.12。
- **来源：** R1、R2、R3 均指出跨项目证据目前只是命中数比较，没有独立真值，也没有证明命中是否对应有用、正确的审计发现。
- **为何影响决策：** 在第二个项目上产生不同命中数，只能证明扫描器可运行和产生信号，不能证明其准确性、召回率、决策价值或“泛化”。

- **最小修复与验证**：在独立项目上建立盲标 gold claims / scope violations，并报告命中对应的正确、遗漏与误报；不再以总命中数单独作为跨项目有效性。验证标准是：跨项目结果可以对独立 ground truth 复算，而不只是一组 hit counts。

3.4 D1 只修复一个 32k 局部点，关键 serving 臂仍未测

- **定位**：p.7–9，Table 4，以及 p.12。
- **来源**：三评共同指出 D1 只覆盖单模型、单设备、32k、G=4、3 轮；16k 并发复测、KV-selector 和 adapter-matched 臂仍是 NOT_MEASURED。G=1 的 29.31 GB 是一致性检查，G=4 才是唯一并发数据点。
- **为何影响决策**：32k 修复点足以撤回“硬件/环境不可行”的旧解释，却不足以恢复原 KV-selective serving 研究的比较结论，也不足以建立吞吐、伸缩或并发机制。
- **最小修复与验证**：完成 16k 并发复测、KV-selector 与 adapter-matched 臂，并增加独立并发工作点/轮次；在此之前维持 NOT_MEASURED。验证标准是：关键比较臂在同模型、设备、作用域和测量协议下都有实际记录，而不是由 32k 修复点替代。

3.5 方法学贡献相对 assurance case、checklist 与 CI 的新颖性和 ICLR 意义偏弱

- **定位**：p.2、p.10。
- **来源**：三评共同认为，与 assurance case、checklist、持续集成式检查相比，当前方法学增量与 ICLR 研究意义不足；R1/R3 因此给 Overall 2，R2 给 4，但三者 Contribution 都是 1。
- **为何影响决策**：即使局部记录真实，论文仍需说明它为何超出单个项目的治理工件；否则贡献保持为一个诚实、可用的项目实例，而不是广泛方法学研究。
- **最小修复与验证**：逐项对照 assurance case、checklist 与 CI，标明 NOT_MEASURED register、按行 scope 标签和 scanner 各自新增的能力，并用独立 ground truth 的跨项目结果验证该增量。验证标准是：新增能力和相对基线的实证差异可逐项复核。

3.6 Table 3 的 C13 推导缺少独立打印输入，却声称 every derived quantity 可重构

- **定位**：p.7，Table 3；相关总括性表述见 p.10。
- **来源**：R2 单独指出 C13 的部分推导值缺少单独打印输入，包括百万 token 外推项，而正文仍声称“every derived”可重构。

- **为何影响决策**：这是可复算性总括性承诺与表内证据之间的直接不一致；即使其他行可复算，该全称命题也不能维持。
- **最小修复与验证**：补齐 C13 每个推导/外推行所需输入、公式和作用域，或把“every derived”改为准确的子集表述。验证标准是：读者只用打印输入即可逐行复算，不能复算的行不再归入全称承诺。

4. 各评审独有重点

- **R1**：在共同问题之外，对正文到 p.10 的格式风险给出较低 Presentation=2；并把该稿主要视为项目治理实例，因此 Overall=2。
- **R2**：独自点出 Table 3 的 C13/百万 token 推导缺输入，却与“every derived reconstructible”相冲突；同时因诚实披露和局部方法学资产给 Overall=4。
- **R3**：与 R1 一样把稿件视为缺少外部验证的项目治理实例，给 Overall=2；另与 R1 共同指出正文到 p.10 的格式风险。

5. 分数分歧说明

R2 给 Overall 4，R1/R3 给 Overall 2；三者 Soundness 均为 2、Contribution 均为 1、Confidence 均为 4、ceiling 均为 4。原摘要记录的差异是：R2 认为诚实撤回与局部方法学资产仍具有有限可用性，因此给 4；R1/R3 认为缺少独立完整性 ground truth、语义覆盖和外部效用验证后，贡献仍主要是单项目治理实例，因此给 2。分歧不是对 32k 修复记录真假的分歧，而是对该局部资产是否足以构成会议论文贡献的分歧。

6. 当前证据上限与可提分证据

- **当前上限**：三评一致为 4。
- **达到 4 所需的最小证据整理**：严格把完整性限定在 author-declared universe；把 regex gate 限定为必要 hygiene filter；补齐 C13 可复算输入或收窄全称承诺；修复 p.10 附近格式风险；继续把 KV-selector、adapter-matched、16k 复测保留为 NOT_MEASURED。
- **解除 ceiling=4 所需的证据**：独立 claim ground truth；对 regex/局部窗口做同义改写绕过测试；跨项目报告正确、遗漏、误报而非仅 hit counts；与 assurance case/checklist/CI 的逐项对照；完成 16k、KV-selector、adapter-matched 及更多并发点测量。

- **32k 修复点的固定边界**：它支持“缺失 inference-mode guard 是应用级缺陷，修复后该点可运行”；它不替代缺失 serving 臂，也不支持吞吐、伸缩或一般系统结论。

7. 作者问题

24. 如何证明 claim ledger 没有漏掉作者未主动枚举的载荷 claim，而不让生成器与检查器彼此循环背书？
25. 27 个检查结构中未覆盖的 9 个如何处理；同义改写是否会无声绕过 regex/局部窗口 gate？
26. 跨项目结果除 hit counts 外，能否对独立 ground truth 报告正确、遗漏和误报？
27. 32k 修复后，何时能在同协议下补做 16k 并发复测、KV-selector 与 adapter-matched 臂？
28. C13 的各个 DERIVED/EXTRAPOLATED 行能否只依赖打印输入逐行复算；若不能，为什么正文仍声称 every derived quantity 可重构？
29. NOT_MEASURED register、按行 scope 标签和 scanner 相比 assurance case、checklist、CI 的新增能力分别是什么，外部验证在哪里？

8. 伦理与评审局限

- 提供的三评摘要没有记录针对 C3 的独立伦理异议；本整理不补写未提交的伦理判断。
- 三位评审 Confidence 均为 4/5。方法有效性判断受限作者自报 claim universe、同源 generator/checker、表面模式 scanner、单个跨项目 hit-count transfer，以及 D1 的单模型/单设备/单 32k 修复点。
- R1/R3 记录了正文到 p.10 的格式风险；本章只保留该风险，不自行判断具体排版缺陷。

P1 — AUDIT-GATE: Pre-Registered Endpoint Operability Audit as a Fire-Gate Meta-Primitive

一句话定位。 论文把 AUDIT-GATE 描述为一个零 GPU 的静态首道检查：它读取多智能体研究运行产生的 fire archive，以 PASS / FAIL / POSTPONE 三态和可重放证书检查端点可操作性；当前稿件同时公开首版规则、观察后修订、冻结层与当前层的差异，以及尚未完成的独立校准。

1. 三评评分

评审	评审侧重	Overall	Soundness	Presentation	Contribution	Confidence	当前证据上限 (ceiling)
R1	technical soundness	2	1	2	1	4	4
R2	experimental rigor	2	2	2	1	4	2
R3	novelty / positioning	2	2	2	1	4	4

2. 共识优点

- 三评认可论文公开报告自身的 FAIL，而不是只呈现成功案例；首版覆盖、观察后修改以及冻结层/当前层差异均被保留。
- 每个判定带有可重放证书，冻结 checker、冻结输入与单命令接口使第三方至少获得明确的重放入口。
- POSTPONE 被设计为正式输出状态，而不是把缺失材料强行折叠为 PASS 或 FAIL。

3. 共识主要问题

3.1 没有独立标注的 fire-archive 总体，无法估计 false-open / false-kill

- 定位：p.1、p.7-9。

- **来源**：R1、R2、R3 均指出，当前没有独立标注的 fire-archive population，因而无法估计误放行（false-open）或误阻断（false-kill）；文中所需的至少 118 个健康档案仍处于阻塞状态。
- **为何影响决策**：现有结果只能证明规则在作者提供的档案与 fixture 上能产生三态输出，不能证明 gate 在真实档案总体上具有可接受的检测与误报行为。它直接限制“可操作”之外的质量保证主张。
- **最小修复与验证**：建立独立标注的 fire-archive 总体，并完成文中登记的至少 118 个健康档案校准；同时纳入真实缺陷档案，报告 false-open、false-kill 及其区间。验证标准是：标签不由规则开发者在同一轮生成，且误放行/误阻断率能从冻结样本逐项复算。

3.2 规则、映射、PRIM3 与 G2 在观察后改变，首版不可回放且开发/验证复用

- **定位**：p.4–6、p.16–21。
- **来源**：三评共同指出，规则、状态映射、PRIM3 和 G2 在观察结果后发生修改；首版规则不能完整回放，同一材料又被用于开发和验证。
- **为何影响决策**：当前成功覆盖混合了规则发现、错误修复和验证，不能被当成对冻结首版的独立确认。若旧版本不可回放，也无法判断哪些 PASS/FAIL 来自原规则，哪些来自观察后的修订。
- **最小修复与验证**：保存并恢复首版规则、映射和输入，使其可独立重放；将修订版冻结后，在未参与规则开发的新档案上验证。验证标准是：每一版均有独立版本标识、输入与证书，且开发集和验证集不复用。

3.3 PRIM3 的 FAIL→PASS 可由同一操作者补写 cause 完成

- **定位**：p.3–4、p.11，以及附录 PRIM3。
- **来源**：R1、R2、R3 均指出，同一操作者只需补写 cause，就可能把 PRIM3 的 FAIL 改成 PASS；当前检查的是字段存在，而非原因是否独立可信。
- **为何影响决策**：这使规则可能验证的是生产者自述完整性，而不是独立证据。对会寻求通过 gate 的同一操作者而言，补写文本本身不能证明原端点可操作。
- **最小修复与验证**：将 cause 的提供与其核验分离，由独立标注或可验证工件决定状态；至少在验证集中禁止同一操作者通过补写 cause 直接改变金标签。验证标准是：只改 cause 文本而不增加独立证据时，不能自动把 FAIL 翻转为 PASS。

3.4 G2 将精确零视为构造性错误，但合法确定性零尚未校准

- **定位：** p.3–4、p.20–21。
- **来源：** 三评共同指出，G2 把精确零当作构造性信号，但合法的确定性零也可能出现；当前没有针对这类零的误杀校准。
- **为何影响决策：** 若合法零会被一律阻断，G2 会制造 false-kill；在缺少独立总体校准时，无法知道这一规则的实际代价。
- **最小修复与验证：** 构建包含合法确定性零与缺陷零的独立标注样本，分别报告 G2 的命中和误杀；在校准前将无法区分的零导向 POSTPONE，而不是默认 FAIL。验证标准是：合法零不再被规则无条件误杀，或其误杀率被明确量化。

3.5 七个自然档案来自同一运行，POSTPONE 主要靠自造 fixture 覆盖

- **定位：** p.6–8 及附录。
- **来源：** 三评共同指出，七个档案均来自同一运行；自然档案中没有 POSTPONE，该分支主要由合成 defect-injected fixtures 覆盖。
- **为何影响决策：** 同一运行的档案共享生产过程和错误模式，不能代表跨运行档案；fixture 能证明分支被执行，却不能证明真实环境中的 POSTPONE 判定有效。
- **最小修复与验证：** 从独立运行、独立操作者或独立项目收集自然档案，并预先标注真实 POSTPONE 情形；保留 fixture 作为单元测试，但不把它替代现场校准。验证标准是：三态均在非合成、跨运行档案中被独立标签覆盖。

3.6 相对普通 CI、schema 检查与实验追踪的增量不足，术语负担较重

- **定位：** p.7–9；术语问题贯穿正文。
- **来源：** 三评共同认为，相比普通持续集成、schema 验证和实验追踪，当前方法的新颖性与增量较弱；大量 seat / round / fire 等内部术语增加理解成本。
- **为何影响决策：** 若新增能力只是现有工程检查的重新命名，Contribution 难以超过 1；高术语密度还使外部读者难以判断哪些组件是真正新增的元原语。
- **最小修复与验证：** 逐项对照普通 CI、schema 检查和实验追踪，标明 AUDIT-GATE 独有的输入、判定与失败覆盖；把 seat / round / fire 映射到通用术语并删去不承载技术差异的命名。验证标准是：每个声称的新增能力都有现有基线不能完成的冻结实例。

4. 各评审独有重点

- **R1**：在完全相同的 Overall=2 判断下，将 Soundness 评为 1，并给 ceiling 4。
- **R2**：在完全相同的 Overall=2 判断下，将 Soundness 评为 2，但 ceiling 只给 2。
- **R3**：评分维度与 R2 相同，但 ceiling 为 4。
- 提供的摘要没有给出三位评审之间额外的独有 issue；上述差异只按已提交评分保留，不补推其原因。

5. 分数分歧说明

三位评审的 Overall 均为 2、Presentation 均为 2、Contribution 均为 1、Confidence 均为 4，因此当前接收判断没有分歧。Soundness 上 R1 为 1、R2/R3 为 2；ceiling 上 R2 为 2、R1/R3 为 4。原始摘要没有提供 ceiling 分歧的解释，本整理不替评审补写原因，也不把三个 ceiling 平均。

6. 当前证据上限与可提分证据

- **当前上限有量表差异**：R2 ceiling=2；R1/R3 ceiling=4。
- **直接对应现有缺口的证据**：独立标注且满足登记规模的真实档案总体；false-open / false-kill 区间；首版与修订版分别可回放；规则开发与验证分离；独立 cause 核验；合法确定性零校准；跨运行自然 POSTPONE；相对 CI/schema/实验追踪的冻结增量案例。
- **仅靠现有 fixture 不能补足的部分**：真实档案总体性能、跨运行泛化、生产者自述与独立证据的区分。

7. 作者问题

30. 所需至少 118 个健康档案的独立标注总体何时可用，届时如何报告 false-open 与 false-kill？
31. 能否完整重放观察前的首版规则、映射、PRIM3 和 G2，并在新档案上单独验证修订版？
32. 同一操作者仅补写 cause 时，为什么 PRIM3 可以从 FAIL 变为 PASS；独立证据由谁核验？
33. G2 如何区分缺陷零与合法确定性零，误杀率如何校准？
34. 能否用跨运行的自然档案覆盖 POSTPONE，而不只依赖自造 fixture？
35. AUDIT-GATE 相比普通 CI、schema 检查和实验追踪新增了哪些可冻结验证的能力？

8. 伦理与评审局限

- 提供的三评摘要没有记录针对 P1 的独立伦理异议；本整理不补写未提交的伦理判断。
- 三位评审 Confidence 均为 4/5。当前评审受限于缺少独立标注总体、档案来自同一运行，以及 POSTPONE 主要由合成 fixture 覆盖。
- “可重放证书”与“已有独立第三方成功重放”不是同一主张；三评认可前者，但当前材料没有把后者作为已完成证据。

P3 — *Is Data Value Path-Ordered or Set-Ordered? A Carrier-Dependent Same-Sample Test Under WSD Schedules*

一句话定位。 论文在两个冻结的 24 维合成 logistic carrier 上，以同一样本、seed 级配对和不同进入位置区分 path-ordered 与 set-ordered 数据价值；sine carrier 给出负偏离，linear carrier 不明确，而构造上 set-ordered 的 ridge negative control 触发了冻结的 sign-blind falsification contract。

1. 三评评分

评审	评审侧重	Overall	Soundness	Presentation	Contribution	Confidence	当前证据上限 (ceiling)
R1	technical soundness	2	1	3	2	4	4
R2	experimental rigor	4	2	3	2	4	4
R3	novelty / positioning	4	2	3	2	4	4

2. 共识优点

- 同一样本身份和 seed 级配对避免把横截面样本差异直接误作进入顺序效应。
- 符号约定与 negative controls 被显式写出，读者可以追踪 headline、校准器和冻结判定条款之间的关系。
- 论文公开 linear carrier 的不明确结果以及 control 失效，没有把所有 carrier 强行叙述成一致结论。

3. 共识主要问题

3.1 Set-ordered ridge 触发冻结的 sign-blind falsification，论文却事后称为规格勘误并保留 headline

- **定位：** p.6–7，Table 6。
- **来源：** R1、R2、R3 均指出，set-ordered ridge 在 canonical allocation 上得到 $g=+0.102$ 、CI [0.028, 0.176]，按冻结的二元、sign-blind consequence clause 已触发 falsification；论文随后把它解释为规格勘误，并因偏差方向与 sine headline 相反而保留 headline。
- **为何影响决策：** 冻结规则的价值正在于结果出现后不能按有利方向重释。即使正偏差不能直接制造负 headline，原合约仍是 sign-blind；事后改为 directional reading 会削弱预注册判定的约束力。
- **最小修复与验证：** 对当前冻结分析按原 sign-blind 条款记录 falsification；若作者认为条款应为 directional，则把它作为新版本预先冻结，并在新样本上复验，而不是回写当前结果。验证标准是：旧版判定与新版判定并列、版本可追踪，当前 headline 不依赖观察后改写旧规则。

3.2 跨 carrier 的正偏差不能保证 sine carrier 内偏差非负

- **定位：** p.7。
- **来源：** 三评指出，ridge control 在部分分配上的正点估计不能推出 sine carrier 内的检测偏差必为非负；至少一个 allocation 的 CI 下界为 -0.066 。
- **为何影响决策：** “正偏差不能制造负 headline”的保护论证只有在与 headline 对应条件下的偏差方向被识别时才成立。跨 carrier、跨 allocation 的符号不能自动转移。
- **最小修复与验证：** 在与 sine headline 对应的 carrier 与 allocation 上直接校准偏差方向，或把“保守”表述限制在实际测得的 ridge/canonical 条件；对 CI 下界 -0.066 的 allocation 不宣称非负已建立。验证标准是：保护性结论由同条件的区间支持，而非跨 carrier 符号外推。

3.3 标准化效应 g 缺少原始分子、分母和近零保护报告

- **定位：** p.5，Equation 4 与 Table 5。

- **来源**：三评指出， $g = \text{mean}(\Delta) / \text{sd}(\Delta)$ 虽给出公式，但未报告原始 $\text{mean}(\Delta)$ 、 $\text{sd}(\Delta)$ 和分母接近零时的保护规则。
- **为何影响决策**：headline 与 control 都依赖 g ；若分母很小，标准化值会变得不稳定。缺少原始组成量使读者无法判断效应来自真实均值偏移还是尺度收缩。
- **最小修复与验证**：对每个载荷单元报告 $\text{mean}(\Delta)$ 、 $\text{sd}(\Delta)$ 、seed 数和近零分母处理；提供可由这些组成量复算的 g 。验证标准是：Table 5 的每个 g 都能从打印值复算，并明确说明 $\text{sd}(\Delta)$ 接近零时是否停止、截断或改报未定义。

3.4 证据只来自两个 24 维合成 logistic carrier，未运行真实 attribution 系统或非凸/LLM 训练

- **定位**：p.1–3、p.7–9。
- **来源**：R1、R2、R3 均指出，当前只有 sine 与 linear 两个 24 维合成 logistic carrier；论文没有实际运行 TRAK、datamodel，也没有真实非凸优化或 LLM 训练证据。
- **为何影响决策**：当前结果最多说明这个零 GPU 合成测试床上的 carrier-dependent 现象，不能确认真实数据 attribution 系统或 LLM 训练路径中存在同样效应。
- **最小修复与验证**：在至少一个实际 TRAK/datamodel 管线和一个真实非凸或 LLM 训练设置中运行同样本、seed 级配对的进入顺序测试；若暂不执行，则把贡献严格限定为合成测试床中的探索性现象。验证标准是：真实管线复用同一符号、negative control 和冻结判定，而不是只展示横截面相关。

4. 各评审独有重点

- **R1**：指出 p.3 §3.1 与 p.5 §4.2 的 early/late entry 可能同时改变曝光次数和累计学习率权重，因此没有隔离“纯顺序”；R2/R3 没有把此点列为 critical。R1 将这一剂量混杂与冻结规则失效合并，给 Overall 2、Soundness 1。
- **R2**：另外指出 p.8 Table 8 的正控 14/16、负控 0/20 没有区间或预设门槛。
- **R3**：提供的摘要没有记录 R3 独有 issue；其 Overall、S/P/C 与 ceiling 均和 R2 相同。

5. 分数分歧说明

R1 给 Overall 2，R2/R3 给 Overall 4；三者 Confidence 均为 4、ceiling 均为 4。原始摘要明确记录：R1 把 early/late 暴露剂量混杂与冻结 sign-blind 规则被事后重释合并，判为 2；R2/R3 认为结果仍是一个有趣但探索性的合成现象，因此给 4。三者都没有把当前稿件评到 6。

6. 当前证据上限与可提分证据

- **当前上限：**三评一致为 4。
- **修复冻结判定所需证据：**当前结果按旧 sign-blind contract 记录 falsification；新的 directional 条款只能在新冻结数据上验证。
- **修复识别所需证据：**在 early/late 之间固定曝光次数和累计学习率权重；在与 sine headline 同 carrier、同 allocation 条件下校准偏差方向。
- **修复可复算性与 control 所需证据：**mean(Δ)、sd(Δ)、近零保护、正控/负控区间与预设门槛。
- **扩大适用范围所需证据：**实际 TRAK/datamodel，以及真实非凸或 LLM 训练设置中的同一样本 seed 级配对复验。

7. 作者问题

36. Table 6 的 $g=+0.102$ 、CI [0.028, 0.176] 已触发冻结 sign-blind 条款后，为什么当前版本仍保留 headline，而不是记录 falsification？
37. 若要把条款改为 directional，能否冻结新版本并在新数据上复验，而不回写旧规则？
38. ridge 的跨 carrier 正偏差如何保证 sine carrier 内偏差非负，尤其某 allocation 的 CI 下界为 -0.066？
39. Equation 4 / Table 5 的 mean(Δ)、sd(Δ) 和近零分母保护分别是多少？
40. early/late entry 是否同时改变曝光次数与累计学习率权重；能否给出只改变顺序的对照？
41. Table 8 的正控 14/16、负控 0/20 对应什么区间与预设通过门槛？
42. 该效应能否在实际 TRAK/datamodel 或真实非凸/LLM 训练中复现？

8. 伦理与评审局限

- 提供的三评摘要没有记录针对 P3 的独立伦理异议；本整理不补写未提交的伦理判断。

- 三位评审 Confidence 均为 4/5。当前判断受限于两个 24 维合成 logistic carrier、未运行真实 attribution 管线，以及 frozen contract 与事后 erratum 的冲突。
- R1 的曝光剂量混杂没有被 R2/R3 列为 critical；本章保留这一评审差异，不把它伪装成三评共识。

P7 — Activation-Tail Turnover as a Predictor of Layer-Wise PTQ Degradation: Two Measured Checkpoints, Observed Not Established

一句话定位。 论文在 Qwen3-4B 与 Qwen3-1.7B 上逐 block 执行 HQQ 4-bit weight-only 量化，检验全精度 activation-tail turnover 能否预测单层 PTQ degradation；4B 的相关约 $p=0.594$ 、1.7B 约 $p=-0.109$ ，但 4B 关系被 depth 吸收，预注册 AUROC gate 也未通过，因此稿件将其报告为“observed, not established”。

1. 三评评分

评审	评审侧重	Overall	Soundness	Presentation	Contribution	Confidence	当前证据上限 (ceiling)
R1	technical soundness	4	2	3	2	4	4
R2	experimental rigor	4	2	3	2	4	4
R3	novelty / positioning	4	2	3	2	4	4

2. 共识优点

- 论文实际执行逐 block HQQ 4-bit 量化，不是只用代理量估计量化损伤。
- 数值边界报告透明：4B turnover-damage $p\approx 0.594$ ，1.7B $p\approx -0.109$ ；4B turnover-depth $p\approx 0.909$ ，而控制 depth 后 turnover-damage 约为 -0.094 。
- 预注册 AUROC 为 0.800 / 0.567 且未通过 gate；论文没有把失败门槛改写为已建立的触发器。
- 三台物理主机的 decisive readout bit-exact，但稿件明确把它解释为流水线确定性、有效独立样本仍为 1，而不是三次独立重复。

3. 共识主要问题

3.1 同一模型内 11–12 个层不独立也不可交换，Fisher 与 bootstrap 给出不同结论

- **定位**：p.3–5、p.7、p.11。
- **来源**：R1、R2、R3 均指出，统计单元是同一 checkpoint 内的 11–12 个层，它们既不独立也不可交换；Fisher 近似与 bootstrap 对显著性给出分歧。
- **为何影响决策**：在层数很少、层间有结构依赖时，常规独立样本相关检验和可交换 bootstrap 的校准不可靠。p 点估计可以作为描述，但不能单独建立一般预测关系。
- **最小修复与验证**：把 checkpoint 而非单层作为独立复制来源，增加独立模型/检查点；在当前数据上并列报告 Fisher、依赖感知 bootstrap 与描述性点估计，不用其中一个选择性定论。验证标准是：方向在多个独立 checkpoint 上重复，而不是由单模型层序列提供伪重复。

3.2 固定探针过采样深层，4B 只测 12 点且含四个最深层

- **定位**：p.3–6、p.8。
- **来源**：三评共同指出，固定 probe 过度代表深层：4B 的 12 个点包含四个最深层，但全模型的 24 层/17 层没有测全；重加权后 4B 的 ρ 从约 0.594 降到 0.401。
- **为何影响决策**：turnover 与 depth 高度相关时，深层过采样会放大总体 rank correlation。当前点估计对 probe 分布敏感，不能被视为全层总体的无偏估计。
- **最小修复与验证**：对 24/17 层做全层测量，或按预先声明的全层抽样权重报告；并列未加权与重加权结果。验证标准是：结论在全层或设计权重下仍满足预设效应阈值，而不是依赖深层过采样。

3.3 Turnover 与 depth 强共线，partial correlation 在小样本下不稳

- **定位**：p.5–6、p.11。
- **来源**：三评共同指出，4B turnover–depth 约 $\rho=0.909$ ，强共线使控制 depth 后的 partial correlation 不稳定；当前 partial 值约为 -0.094 。
- **为何影响决策**：原始 $\rho \approx 0.594$ 更像 depth proxy，而非 turnover 的独立预测信息。小层数下强共线又使“控制 depth 后为零/负”的数值本身不够稳定。

- **最小修复与验证**：在更多独立 checkpoint 和全层数据上评估 depth-only、turnover-only 与二者联合模型；明确报告共线诊断和样本外预测，而不只依赖 partial correlation。验证标准是：turnover 在给定 depth 后仍提供稳定的样本外增益，或将其限定为 depth proxy。

3.4 域只有 64+64 个模板，NTM max 可能受长度/padding 驱动

- **定位**：p.2–4、p.8。
- **来源**：三评共同指出，校准/部署域各只有 64 个模板；NTM max 可能受到序列长度和 padding 影响。padding 修复翻转了 4/12 个层标签，且许多层的变化处在噪声尺度。
- **为何影响决策**：若候选信号主要响应长度或 padding，而不是部署分布变化，其预测含义会被误识别。4/12 标签翻转显示结果对实现细节并不稳定。
- **最小修复与验证**：在长度匹配、padding 处理冻结的更大真实域上重算 turnover，并把 pad 修复前后逐层变化并列；预先设定噪声阈值。验证标准是：层标签和相关方向不再因 padding 修复大规模翻转，且信号超过测量噪声。

3.5 预注册 8 格仅执行 2 格，fallback damage-reduction 未运行，AUROC gate 未过

- **定位**：p.6–9、p.12。
- **来源**：三评共同指出，预注册 8 个配置格只运行了 2 个，fallback damage-reduction 实验没有执行；可测 AUROC 0.800/0.567 未通过预注册门槛。
- **为何影响决策**：当前证据不能支持可部署 trigger certificate，也无法回答信号驱动 fallback 是否实际减少损伤。未运行配置使跨条件稳健性仍未知。
- **最小修复与验证**：完成剩余 6 格和预注册 fallback damage-reduction；保持原 AUROC 门槛。验证标准是：冻结 gate 在预注册矩阵中通过，且 fallback 在相同部署域中产生预设的损伤降低；否则继续报告为未建立。

3.6 只有同家族两个 checkpoint，cross-carrier 差异未正式建立

- **定位**：p.1–9、p.12。
- **来源**：三评共同指出，只有 Qwen3 同家族的 4B 与 1.7B 两个 checkpoint；一个正、一个近零不足以正式建立 carrier-dependent 规律。

- **为何影响决策**：两点差异可以描述，却不能区分规模、checkpoint 特性、抽样或家族效应，也不能建立一般跨 carrier 异质性。
- **最小修复与验证**：增加独立模型家族和多个规模/checkpoint，并以 checkpoint 为单位检验异质性。验证标准是：cross-carrier 差异具有独立复制，而不只是两个同家族点的对照。

3.7 缺少静态量化敏感度、Hessian 等强基线

- **定位**：p.2–9。
- **来源**：三评共同指出，候选信号没有与静态量化敏感度、Hessian 等更强基线进行同床比较。
- **为何影响决策**：即使 turnover 在部分 checkpoint 有相关，也尚未证明它提供超出现有敏感度指标的预测信息或部署价值。
- **最小修复与验证**：在相同层、相同 PTQ damage 终点和相同数据划分上加入静态敏感度/Hessian 基线，报告 AUROC、rank correlation 及给定 depth 后的增量。验证标准是：turnover 对强基线有稳定增益，或将贡献降为候选信号的边界测量。

4. 各评审独有重点

- 三位评审的 Overall、S/P/C、Confidence 和 ceiling 完全一致；提供的摘要也没有记录任何只属于一位评审的 issue。
- 因而本节不人为制造评审差异：所有列出的主要问题均作为三评共识保留。

5. 分数分歧说明

三位评审均给 Overall 4、Soundness 2、Presentation 3、Contribution 2、Confidence 4、ceiling 4，没有评分分歧。该一致判断保留了论文的透明负结果价值，但认为当前证据只能支持探索性边界发现，不能支持已建立的预测器或部署触发器。

6. 当前证据上限与可提分证据

- **当前上限**：三评一致为 4。
- **统计独立性**：多个独立 checkpoint、全层或设计加权测量、依赖感知推断。
- **去除 depth / probe 混杂**：全层覆盖、长度与 padding 匹配、depth-only/turnover-only/联合样本外比较。

- **完成预注册**：其余 6 个配置格、fallback damage-reduction，以及原 AUROC gate。
- **外部与相对验证**：跨模型家族复制，并与静态量化敏感度、Hessian 等强基线同床比较。

7. 作者问题

43. 在层既不独立也不可交换、Fisher 与 bootstrap 结论分歧时，哪个推断是预先指定的，如何避免层级伪重复？
44. 为什么 4B 的 12 个 probe 含四个最深层而未测全 24/17 层；重加权后 $p=0.401$ 应如何影响 headline？
45. 在 turnover–depth $p\approx 0.909$ 、partial $p\approx -0.094$ 时，turnover 提供了哪些独立于 depth 的预测信息？
46. padding 修复为何翻转 4/12 层标签；长度匹配和噪声阈值下结果是否仍成立？
47. 预注册的其余 6 格和 fallback damage-reduction 何时执行；AUROC 0.800/0.567 未过门时为何还能支持何种范围的结论？
48. 两个同家族 checkpoint 如何正式建立 cross-carrier 差异？
49. 与静态量化敏感度或 Hessian 基线相比，turnover 是否有增量？

8. 伦理与评审局限

- 提供的三评摘要没有记录针对 P7 的独立伦理异议；本整理不补写未提交的伦理判断。
- 三位评审 Confidence 均为 4/5。评审受限于两个同家族 checkpoint、同模型内少量层、64+64 模板域、未完成的预注册矩阵和未执行的 fallback 实验。
- 三主机 bit-exact 只证明流水线确定性，不能在本章中重新解释成三个独立科学重复。

S1 — *SparseForge: Recovery-Induced Compression of Cross-Support Spread in 2:4 LLM Sparsification — A Registered Negative Result at 0.118 pp Below the Harness's Sampling-Noise Scale*

一句话定位。 论文对 ALPS、ELSA-4096、ProxSparse 三种固定 2:4 support 使用同一标称 625M-token、rank-16 SLoRB recovery，报告 AVG-9 的 cross-support range 从 2.675 pp 压缩到 0.118 pp；但三端点没有保留逐题配对预测，因此 0.118 pp 的联合 range 不确定性并未被识别。

1. 三评评分

评审	评审侧重	Overall	Soundness	Presentation	Contribution	Confidence	当前证据上限 (ceiling)
R1	technical soundness	2	2	3	1	4	4
R2	experimental rigor	4	2	3	2	4	4
R3	novelty / positioning	4	2	3	2	4	4

2. 共识优点

- 三个 support 使用同一标称 625M-token recovery，聚合算术与 cross-support range 的计算透明。
- 任务级数值、SLoRB 分支仍在线、无法访问的 checkpoint / manifest / corpus 均被充分披露，没有把缺失工件写成已验证状态。
- 论文明确区分当前历史测量与尚未完成的 exact-2:4 导出或组件归因。

3. 共识主要问题

3.1 0.118 pp 只与单 checkpoint 的 0.52 pp 边际 SE 比较，不能建立联合 range 的“registered negative result”

- **定位：**标题、摘要、p.5 §5.2、p.11–12 Table 5。
- **来源：**R1、R2、R3 均指出，论文把三端点 $\max\text{--}\min=0.118$ pp 与单 checkpoint 的 0.52 pp 边际 binomial SE 比较，并据此在标题/摘要称“registered negative result”；但逐题预测未保留，三端点联合 range 的不确定性无法计算。
- **为何影响决策：**单端点边际 SE 不是 $\max\text{--}\min$ range 的联合标准误，也不能给出三 support 是否统计不可区分的结论。0.118 pp 可以是历史点估计，却不足以支撑标题级负面结果。
- **最小修复与验证：**恢复或重新生成三 support 的逐题配对预测，直接估计 pairwise differences 与联合 range 的区间；在此之前把标题和摘要收窄为“observed 0.118 pp range”，不称已注册的统计负结果。验证标准是：联合区间由同题配对数据估计，而非用单 checkpoint 0.52 pp SE 替代。

3.2 每个 support 只有单一 recovery endpoint / base seed0，没有多 seed

- **定位：**p.5–7、p.14、p.17。
- **来源：**三评共同指出，每个 support 只有一个恢复后 endpoint，并共享 base seed0；没有多 seed 恢复来估计训练或恢复过程变异。
- **为何影响决策：**即使 eval-sampling 联合区间可恢复，单 seed 仍无法判断 0.118 pp 压缩是否对恢复随机性稳定。当前 spread 可能是这一次恢复轨迹的结果。
- **最小修复与验证：**对三个 support 在匹配预算、语料与超参数下运行多个独立 seed，并保存逐题预测；以 seed 和项目级预测共同估计 spread。验证标准是：cross-support compression 在多 seed 上稳定，而不是只存在于 base seed0。

3.3 AVG-9 接近掩盖任务级 2.88–3.22 pp 范围与方向抵消

- **定位：**p.6 Table 1、p.12。
- **来源：**三评共同指出，AVG-9 虽接近，但 BoolQ 的 support range 约 3.22 pp、RTE 约 2.88 pp，任务间方向可能相互抵消。

- **为何影响决策**：聚合均值上的 0.118 pp 不能证明各任务 support choice 都无关；大任务级差异会被正负抵消隐藏。
- **最小修复与验证**：对九个任务逐项给出配对差异、联合区间与多重校正，并明确聚合权重；不把 AVG-9 压缩外推为逐任务不可区分。验证标准是：任务级结论分别有不确定性支持，且聚合结果不依赖方向抵消。

3.4 SLoRB 推理时仍在线，未完成 fold→2:4 re-project 与导出前后质量/速度验证

- **定位**：p.2、p.4–7、p.13、p.15–16。
- **来源**：三评共同指出，SLoRB branch 在推理时仍在线；没有 fold 回稀疏权重、重新投影为 exact 2:4、逐组断言，也没有导出前后质量与速度测量。
- **为何影响决策**：当前 checkpoint 不是已验证的纯 exact-2:4 部署工件，因此不能由在线分支结果推出原生 2:4 部署质量或加速。
- **最小修复与验证**：完成 SLoRB fold、exact 2:4 re-project 和逐组 2-of-4 断言；在同一硬件上报告导出前后质量、吞吐/延迟。验证标准是：导出工件确实满足逐组 exact 2:4，且质量和速度均来自导出后实测。

3.5 5B checkpoint、manifest 与语料不可达，恢复语料无法审计且预算/语料不匹配

- **定位**：p.5–8、p.16–17。
- **来源**：三评共同指出，5B checkpoint、manifest 与训练/恢复语料位于不可达档案；语料许可、构成和污染不能审计。RTE 数值异常需要解释；SparseForge 与 AST 比较混合了不同预算和语料。
- **为何影响决策**：无法访问关键工件时，历史数值只能按当前披露的有限 provenance 使用；跨方法比较又受到预算与语料混杂，不能归因于方法本身。
- **最小修复与验证**：恢复 checkpoint、manifest、语料清单与哈希；对 RTE 异常给出可复算数据；在同预算、同语料下重跑 SparseForge 与 AST。验证标准是：比较臂只改变方法，不同时改变恢复预算/语料，且第三方能审计语料与端点来源。

3.6 组件没有消融，且缺少 SparseForge 自己的匹配 625M arm

- **定位**：p.4–8、p.16–17。

- **来源**：三评共同指出，curvature score、soft-to-hard annealing、rank-16 SLoRB 等组件没有匹配消融；SparseForge 自己的匹配 625M arm 也缺失。
- **为何影响决策**：当前证据只支持整套历史恢复后的聚合观测，不能把 spread compression 或质量归因到任一组件，也不能与缺失的匹配 SparseForge arm 公平比较。
- **最小修复与验证**：在相同 625M token、语料、seed 设计下加入 SparseForge 匹配 arm，并逐一消融 curvature、annealing、SLoRB。验证标准是：每个组件的增量由只改变该组件的匹配对照测得；否则继续把组件写作 pipeline background。

4. 各评审独有重点

- **R1**：认为标题级“registered negative result”失去统计支持，且当前 Contribution 只能为 1，因此给 Overall 2。
- **R2**：认为诚实的历史测量与完整披露仍有窄贡献，给 Contribution 2、Overall 4。
- **R3**：与 R2 相同，给 Contribution 2、Overall 4；提供的摘要没有记录 R2/R3 之间额外的独有 issue。

5. 分数分歧说明

R1 给 Overall 2、Contribution 1；R2/R3 给 Overall 4、Contribution 2。三者 Soundness 均为 2、Presentation 均为 3、Confidence 均为 4、ceiling 均为 4。原始摘要明确记录：R1 认为 0.118 pp 相对 0.52 pp 的论证不能支持标题级负面结果，因此判 2；R2/R3 认为，在严格作为历史描述和透明边界报告时仍有狭窄贡献，因此判 4。

6. 当前证据上限与可提分证据

- **当前上限**：三评一致为 4。
- **统计证据**：三 support 逐题配对预测、pairwise / joint-range 区间、多 seed recovery，以及任务级不确定性与多重校正。
- **部署证据**：SLoRB fold、exact-2:4 re-project、逐组断言、导出前后质量和速度。
- **可审计性**：恢复 5B checkpoint、manifest、语料清单与哈希，解释 RTE 异常。
- **归因证据**：同预算/同语料的 SparseForge 625M arm、AST 对照和组件消融。
- **在这些证据完成前的最小措辞边界**：0.118 pp 只是当前历史端点的 AVG-9 点估计 range，不是由 0.52 pp 单端点 SE 建立的联合负结果。

7. 作者问题

50. 没有逐题预测时，为什么单 checkpoint 的 0.52 pp 边际 SE 可以支持三 support max-min=0.118 pp 的联合“registered negative result”？
51. 能否重新生成逐题配对预测，并直接报告 pairwise 与 joint-range 区间？
52. 单 base seed0 下的 0.118 pp 是否能在多个匹配 recovery seed 上复现？
53. AVG-9 接近时，BoolQ≈3.22 pp、RTE≈2.88 pp 的任务级范围和方向抵消应如何解释？
54. 何时完成 SLoRB fold、exact-2:4 re-project、逐组断言及导出前后质量/速度测量？
55. 能否恢复 5B checkpoint、manifest 和语料清单，并解释 RTE 异常及语料许可/污染边界？
56. SparseForge 与 AST 能否在相同 625M 预算和语料下比较，并加入匹配 SparseForge arm 与组件消融？

8. 伦理与评审局限

- 三位评审均将 ethics concern 标为 **true**：恢复语料与 manifest 不可达，因此语料许可、隐私和污染无法验证。
- 三位评审 Confidence 均为 4/5。当前判断受限于单 seed、缺失逐题预测、无法访问的 5B 工件与语料，以及未完成 exact-2:4 导出。
- 伦理 concern 来自 provenance 无法核验；本整理不把它扩写为已经发现许可、隐私或污染违规。

独立元评审与跨论文共同问题

元评审的角色 M1 只在 21 份隔离评审全部提交后读取三评结果。元评审分是面积主席式综合，不是第四次独立评分；它会在分歧中判断哪些问题真正驱动最终决定。

论文	三评	三评中位数	元评审	证据上限	元评审建议
C1	4 / 6 / 6	6	6	6	Marginally above
C2	4 / 6 / 6	6	4	6	Marginally below
C3	2 / 4 / 2	2	2	4	Reject
P1	2 / 2 / 2	2	2	4	Reject
P3	2 / 4 / 4	4	4	4	Marginally below
P7	4 / 4 / 4	4	4	4	Marginally below
S1	2 / 4 / 4	4	4	4	Marginally below

总体判决 C1 是唯一获得元评审 6 的论文；C2 虽有两位独立评审给 6，但元评审因核心干预混杂与 reader 敏感性降为 4。C3、P1 为 2；P3、P7、S1 为 4。

C1 元评审

M1 : 6 / 10 · 上限 6 / 10 这是本批次最接近接收线的一篇：系统化的 null-calibration 报告协议、透明表格和多臂结果具有实际价值；但当前版本把报告 floor 解释成比较有效性的 gate，力度超过了已检验的零假设族与统计程序。

接受前必须解决

- 把 Table 15 的同时通过计数由文中的 15/17 核对并更正为交集 13/17，同时说明 OLMo-2 缺少 chance-side bootstrap 的影响。
- 把 best-constant 标签选择纳入 bootstrap 或使用嵌套/选择感知重采样，并对共享题目与多臂依赖给出总体不确定性。
- 将“有效性 gate”缩窄为针对已实现 input-blind null family 的诊断规则，明确其不构成充分有效性证明。

- 补足与最近邻校准、无信息基线和选择后推断工作的功能级差异，并明确 v2 分析的后验性质。

提分路径

仅用当前证据：仅用现有证据可完成：纠正计数、降低 gate 语义、披露选择与依赖限制、重写最近邻贡献边界。

需要新增证据：若要稳固 6 分：运行选择感知/联合重采样，并在自然失效模式或更多常规模型上检验该规则，而不只依赖人工损伤臂。

C2 元评审

M1 : 4 / 10 · 上限 6 / 10 匹配 $j=0$ 控制与明确的负面方向是有价值的系统测量；然而 A/E 对比并非纯 depth 操作，且核心 reader 对 first-task-label/strip 规则敏感，因此元评审认为当前因果和系统结论尚未越过接收线。

接受前必须解决

- 把 A/E 结果改写为“深度与可见上下文集合共同改变”的复合干预，除非新增真正上下文匹配的深度对照。
- 用当前输出重算至少一种稳健 reader（或人工核验子集），报告不同解析规则下方向和幅度是否保持。
- 披露 4k 是从 2k/4k/8k 中形成的重点结果，并做选择校正或同时报告三点的联合区间。
- 把约 0.3 GB、约 26 次读取的 break-even 限定为当前模型、硬件、批量与实现下的局部估计。

提分路径

仅用当前证据：仅用现有证据可完成：重新解析现有输出、并列完整长度网格、收窄 depth-only 与 break-even 表述。

需要新增证据：若要恢复 6 分：做上下文集合严格匹配的深度实验，并扩展到更多模型、任务、硬件和端到端实现。

C3 元评审

M1 : 2 / 10 · 上限 4 / 10 NOT_MEASURED 注册表和对 D1 的局部修复体现了罕见的诚实方法学态度；但生成器与检查器共享作者自定义 ledger，没有独立真值，跨项目命中计数也不能证明语义完整性或实际效用。

接受前必须解决

- 建立由独立标注者或外部工件形成的遗漏/误报 ground truth，并报告 precision、recall 与分歧处理。
- 将 regex/局部窗口覆盖与真正的语义保证分开，尤其解释 27 个结构中未覆盖的 9 个结构。
- 补齐 Table 3 中 C13 等派生量的原始输入，使“每个派生量可重构”的承诺可以机械验证。
- 与 CI、实验追踪、assurance case 和 checklist 做最近邻功能比较，说明增量而非只强调新术语。

提分路径

仅用当前证据：现有证据最多支持一个范围受限的实践说明；可通过缩窄完整性主张、补充可重构输入和限制声明提升可信度。

需要新增证据：要达到 4 分以上，需要独立标注的外部语料、盲评校准和能体现减少真实遗漏/错误决策的效用研究。

P1 元评审

M1 : 2 / 10 · 上限 4 / 10 预注册、自我判负和保留证书值得肯定；但 gate 的正确性没有在独立真值上校准，首版规则不可回放，PRIM3 可由同一操作者补写 cause 通过，因而核心治理承诺目前是自证式的。

接受前必须解决

- 冻结并保留规则的每个版本，将开发档案与验证档案分离，避免观察后改动覆盖首版。
- 用独立标注的真实 fire-archive 总体估计 false-open、false-kill，并报告不确定性。
- 让 PRIM3 的 cause 证据来自不可由被审计操作者单方补写的独立来源或签名工件。
- 重新校准 G2 的 exact-zero 规则，证明合法确定性零不会被系统性误杀。
- 与普通 CI/schema validation/实验追踪做增量比较并减少不必要术语。

提分路径

仅用当前证据：现有材料只能支撑流程原型与失败案例；应删除已验证通用 meta-primitive 的暗示，并完整披露规则演化。

需要新增证据：要达到 4 分，需要跨独立运行和团队的真实档案、盲标真值与预先冻结的外部验证；当前证据无法仅靠改写越过 2 分。

P3 元评审

M1 : 4 / 10 · 上限 4 / 10 同一样本、不同调度位置的设计方向有意义，但 early/late 同时改变暴露次数和累计学习率，是 timing/dose 复合干预；冻结的 sign-blind falsification 已触发后又被事后解释为规格勘误，削弱了 headline 的可证伪性。

接受前必须解决

- 把“纯路径顺序效应”改为 timing/dose 复合效应，除非新增匹配暴露次数与累计学习率的设计。
- 恢复并正面报告冻结控制的原始判定，区分预注册结论、事后解释与探索性分析。
- 逐格报告标准化效应 g 的原始分子、分母、近零保护和不确定性。
- 不要把其他 carrier 的正偏差迁移为 sine carrier 的非负保证。

提分路径

仅用当前证据：通过收窄因果主张、报告原始 g 组成并承认校准失败，可使论文与现有证据一致，但元评审上限仍为 4。

需要新增证据：更高分需要真正匹配 exposure/dose 的顺序实验，并在非凸训练或真实 attribution/LLM 系统上外部验证。

P7 元评审

M1 : 4 / 10 · 上限 4 / 10 论文诚实地把结果写成 observed-not-established，且执行了真实 block quantization；但层不是独立样本、采样偏深，turnover 与 depth 近共线，最终信号更像深度代理而不是已建立的独立预测因子。

接受前必须解决

- 以模型为更高层单位处理层内相关，报告 cluster/model-aware 区间，而不是把 11–12 个层当可交换样本。

- 解释并修正固定探针的深层过采样，增加均匀或预定义全层覆盖。
- 在小样本和强共线条件下对 depth 调整做稳健性分析，并与静态量化敏感度、Hessian 等强基线比较。
- 完成或明确放弃预注册 8 格与 fallback，区分未运行、未过 gate 和真正负结果。

提分路径

仅用当前证据：现有证据支持两个同家族 checkpoint 上的探索性相关观察；标题和结论应继续保持这一边界。

需要新增证据：要提高上限，需要更多模型家族、均衡层采样、更大/更多样域、完整预注册网格与对照基线。

S1 元评审

M1 : 4 / 10 · 上限 4 / 10 匹配 nominal endpoints 与透明工件叙述是优点；但 0.118 pp 的 max-min 范围不能与单检查点 0.52 pp 边际 SE 直接比较来证明统计负面或等价，且任务平均掩盖了 BoolQ/RTE 的方向抵消。

接受前必须解决

- 删除或重命名“registered negative result”，除非对 support 间差异做联合、多 seed 的等价/非劣检验。
- 报告任务级结果和异质性，避免 AVG-9 用方向抵消支持机制无差异。
- 完成 SLoRB fold→exact 2:4 re-project，并比较导出前后质量、稀疏性和真实速度。
- 披露或恢复 5B checkpoint、manifest、语料来源和许可；在不可审计前保留伦理与污染风险标记。
- 增加组件消融与 SparseForge 自身的匹配 625M arm。

提分路径

仅用当前证据：若不新增实验，只能把结论降为单次运行下的描述性近似，并明确无法作统计等价判断。

需要新增证据：要巩固 4 分并争取更高分，需要联合预测/多 seed、任务级分析、可部署导出验证、可审计谱系和匹配消融。

五类反复出现的决策驱动问题

1. **主张强于可识别对象** C1 把已实现的 input-blind floor 靠近有效性 gate ; C2 把深度与可见上下文共同变化写成 depth-only ; P3 把 timing/dose 复合干预写成纯顺序效应 ; S1 把描述性近似写成统计负面结论。
2. **控制与验证缺少独立性** C3 的 ledger 生成与检查同源 ; P1 的规则、cause 和被审计档案缺独立真值 ; P7 的层采样和深度共线使预测因子缺少正交验证。
3. **推断单位或统计契约不闭合** C1 缺 selection-aware 联合重采样 ; C2 的 4k 重点结果有选择性 ; P7 把相关层当独立样本 ; S1 用边际 SE 判断 max-min 范围。
4. **工件与数据谱系不可独立复核** C2 的部分输入不可恢复 ; C3 的若干派生量缺原始输入 ; P1 的首版规则被覆盖 ; S1 的 checkpoint、manifest 和恢复语料不可审计。
5. **新颖性定位未对准最近邻** C3、P1 尤其需要与 CI、assurance case、schema validation 和实验追踪做功能级比较 ; 其余论文也应把贡献边界放在真正相邻的测量或机制工作上。

按优先级的跨论文修订原则

57. 先修复会翻转结论的实现、统计或数据谱系问题，再讨论措辞与叙事。
58. 如果无法新增证据，应主动缩窄标题、摘要和贡献边界，而不是用更强语气弥补实验缺口。
59. 新实验优先选择最小可证伪的匹配/正交对照，并冻结推断单位、阈值和分析代码。
60. 所有核心表格应能由匿名工件包在干净环境中机械重建，并保留逐样本或逐运行记录。
61. 相关工作应围绕论文真正声称的新知识建立最近邻矩阵，而非只列背景模型或同类任务。

附录：评审标识、rubric 与审计边界

21 份独立评审标识

论文	R1 技术	R2 实验	R3 新颖性
C1	C1-R1-TECH	C1-R2-EXP	C1-R3-NOVELTY
C2	C2-R1-TECH	C2-R2-EXP	C2-R3-NOVELTY
C3	C3-R1-TECH	C3-R2-EXP	C3-R3-NOVELTY
P1	P1-R1-TECH	P1-R2-EXP	P1-R3-NOVELTY
P3	P3-R1-TECH	P3-R2-EXP	P3-R3-NOVELTY
P7	P7-R1-TECH	P7-R2-EXP	P7-R3-NOVELTY
S1	S1-R1-TECH	S1-R2-EXP	S1-R3-NOVELTY

正式 reviewer prompt 的核心要求

- 先识别问题、贡献、假设和证据，再测试每项 headline claim 是否被证据支持。
- 先判定问题严重度，再给分；总分评价当前版本，而不是修改后的潜力。
- 每个问题引用具体页码、章节、图表或证据对象，并给出修复与验证测试。
- 不因论文没有运行无关实验而惩罚，也不因自信措辞或篇幅而奖励。
- 总分只能为 2、4、6、8、10；维度 1-4；信心 1-5。

本报告的边界

限制 评审者未访问论文声称存在但未包含于 PDF 的代码、日志、检查点或补充工件；未做外部联网文献审计；因此“无法核验”不等同于断言结果为假。三位评审均为隔离 AI 子代理，元评审 M1 只在评分提交后介入；内部评分不保证实际录用。